

Nhận dạng khuôn mặt

Face Recognition

Nhóm 10

Đỗ Thùy Linh - 20001940

Đinh Phương Linh - 20001941

Trịnh Thị Ngọc Mai - 20001948

Nguyễn Thị Phương Ngân - 20001953

Nguyễn Thị Bích Ngọc - 20001957

Khoa Toán - Cơ - Tin học
Trường Đại học Khoa học tự nhiên

Hà Nội - 2023

- 1 Giới thiệu
- 2 Thuật toán di truyền
- 3 Thuật toán KNN
- 4 Frequent Pattern (FBM)

- 1 Giới thiệu
- 2 Thuật toán di truyền
- 3 Thuật toán KNN
- 4 Frequent Pattern (FBM)

- 1. Tổng quan :

Nhận dạng khuôn mặt là quá trình xác định và xác minh danh tính của một cá nhân dựa trên việc phân tích và nhận biết các điểm độc nhất trên khuôn mặt của họ.

- 2. Những khó khăn:

- Tự thể góc chụp
- Sự xuất hiện hoặc thiếu một số thành phần trên khuôn mặt
- Biểu cảm khuôn mặt
- Sự che khuất
- Điều kiện của ảnh
- Nền ảnh phức tạp
- Màu sắc

Giới thiệu

3. Tầm quan trọng

- An ninh và an toàn
- Quản lý danh tính, quản lí nhân sự
- Giao dịch điện tử và bảo mật
- Trải nghiệm người dùng, hệ thống giao tiếp thông minh giữa người và máy
- Tự động hóa
- Vai trò quan trọng nghiên cứu khoa học
- Dịch vụ giải trí
- Phân tích cảm xúc...

Giới thiệu

4. Yêu cầu cho đề tài

- Dữ liệu thực nghiệm: Tập dữ liệu đủ lớn và đa dạng CMU
- Mục tiêu đề tài: Thiết kế phần mềm trên nền tảng Web nhận dạng khuôn mặt trực tuyến
- Yêu cầu:
 - Thực hiện 3 cách phân loại
 - Hiển thị độ chính xác, điểm F1 của các phương pháp
 - Thử nghiệm với bộ dữ liệu gương mặt thật

Giới thiệu

5. Giới thiệu về bộ dữ liệu CMU

Bộ dữ liệu CMU (Carnegie Mellon University) là một tập hợp các bộ dữ liệu được sử dụng trong nhiều nghiên cứu về trí tuệ nhân tạo, học máy và thị giác máy tính.

- Kiểu dữ liệu: Kiểu hình ảnh
- Nguồn: Thuộc về chủ sở hữu ban đầu và nhà tài trợ: Tom Mitchell - Trường Khoa học Máy tính - Đại học Carnegie Mellon
- Định dạng dữ liệu:

`<userid> <pose> <expression> <eyes> <scales>.pgm`

Trong đó:

`<userid>` là id người dùng của người trong ảnh.

`<pose>` là vị trí đầu của người đó.

`<expression>` là nét mặt của một người.

`<eyes>` là trạng thái mắt.

`<scale>` là tỷ lệ của hình ảnh.

Giới thiệu

4. Các hướng phát triển trong tương lai

- Phát triển các mô hình học sâu
- Áp dụng học có giám sát và học không giám sát
- Tăng cường tính bảo mật
- Phát triển các ứng dụng mới
- Tăng cường độ chính xác cho nhận dạng khuôn mặt trong điều kiện khó khăn
- Sử dụng các phương pháp khác nhau để tăng độ chính xác của nhận dạng khuôn mặt
- Phát triển các giải pháp đáp ứng các yêu cầu về bảo vệ thông tin cá nhân

- 1 Giới thiệu
- 2 Thuật toán di truyền**
- 3 Thuật toán KNN
- 4 Frequent Pattern (FBM)

Thuật toán di truyền

Giới thiệu về thuật toán

Thuật toán di truyền (genetic algorithm) là một phương pháp để giải quyết các vấn đề tối ưu hóa dựa trên chọn lọc tự nhiên, quá trình thúc đẩy sự tiến hóa sinh học.

Sự kết hợp của các giải pháp khác nhau được thông qua thuật toán dựa trên thuyết tiến hóa Darwin để tìm ra các giải pháp tốt nhất. Các giải pháp kém hơn sau đó được thay thế bằng con của các giải pháp tốt.

Human Genetic	GA Terminology
chromosomes	bit strings
genes	features
allele	feature value
locus	bit position
genotype	encoded string
phenotype	decoded genotype

Bảng: Di truyền ở người và thuật toán di truyền

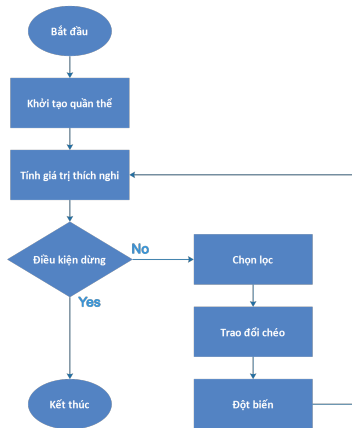
Thuật toán di truyền

Giới thiệu về thuật toán

- Mỗi cá thể trong thuật toán di truyền sẽ biểu diễn một giải pháp của bài toán.
- Mỗi cá thể trong thuật toán di truyền chỉ có 1 NST. Do đó, khái niệm cá thể và NST trong thuật toán coi như tương đương.
- Một NST được tạo thành từ nhiều gen, mỗi gen có thể có các giá trị khác nhau để quy định một tình trạng nào đó. Trong thuật toán di truyền, một gen được coi như một phần tử trong chuỗi NST.

Thuật toán di truyền

Triển khai thuật toán



Hình: Sơ đồ thuật toán GA

Hai điều kiện dừng cơ bản:

- Dựa trên cấu trúc nhiễm sắc thể, kiểm soát số gene được hội tụ. Nếu số gene được hội tụ tại 1 điểm hoặc vượt quá điểm đó thì kết thúc.
- Dựa trên ý nghĩa đặc biệt của nhiễm sắc thể, đo sự thay đổi của giải thuật sau mỗi thế hệ, nếu thay đổi này nhỏ hơn một hằng số xác định thì giải thuật kết thúc.

Thuật toán di truyền

Ưu nhược điểm của thuật toán

Ưu điểm:

- Tốt khi dữ liệu có nhiều nhiễu.
- Thuật toán di truyền tìm kiếm trên tập các điểm mà không phải điểm riêng lẻ nên khắc phục được sự phụ thuộc vào giá trị khởi tạo.
- Thuật toán di truyền sử dụng các quy tắc chuyển đổi xác suất và không cần các quy tắc xác định.
- Có thể dễ dàng song song hóa.
- Hoạt động tốt trên các bài toán liên tục hoặc rời rạc.
- Thuật toán di truyền yêu cầu ít thông tin hơn.
- Thuật toán di truyền mang tính xác suất, phụ thuộc vào thời gian, phi tuyến tính, không cố định.

Thuật toán di truyền


Ưu nhược điểm của thuật toán

Nhược điểm:

- Độ phức tạp tính toán cao.
- Thuật toán di truyền yêu cầu ít thông tin về bài toán nhưng viết và biểu diễn khó khăn.
- Thuật toán di truyền cần định nghĩa đặc biệt.

Thuật toán di truyền

Lựa chọn đặc trưng



Hình: Lựa chọn đặc trưng với GA

Mỗi đặc trưng có 2 trường hợp có thể xảy ra: được lựa chọn, không được lựa chọn.

Các đặc trưng được lựa chọn sau đó được xếp hạng và dựa trên bảng xếp hạng, tập con gồm n phần tử tốt nhất được lựa chọn để tồn tại đến thế hệ tiếp theo.

Những cá thể còn lại trong quần thể hiện tại được di truyền qua lai chéo (crossover) và đột biến (mutation). Tập con được lựa chọn, tập con kết quả của lai chéo và đột biến tạo thành thế hệ tiếp theo.

Thuật toán di truyền

Áp dụng vào bài toán nhận dạng khuôn mặt

Trong bài toán nhận dạng khuôn mặt, thuật toán di truyền được sử dụng để trích xuất đặc trưng, phục vụ cho quá trình phân loại.

Các bước thực hiện:

- 1 Đọc dữ liệu từ file, gán nhãn cho ảnh bằng tên tệp tương ứng với tên từng người.
- 2 Xử lý dữ liệu: Làm phẳng dữ liệu ảnh và chuyển dữ liệu thành Numpy array, dtype = float.
- 3 Áp dụng thuật toán di truyền để lựa chọn đặc trưng: sử dụng GeneticSelectionCV từ thư viện scikit-genetic.
- 4 Dùng mô hình phân loại Random Forest Tree để phân loại.
- 5 Đánh giá.

Thuật toán di truyền

Áp dụng vào bài toán nhận dạng khuôn mặt

Áp dụng thuật toán di truyền vào nhận dạng khuôn mặt cho kết quả với độ chính xác cao.

Accuracy	97.88%
F1 score	97.38%

Bảng: Kết quả dùng GA

- 1 Giới thiệu
- 2 Thuật toán di truyền
- 3 Thuật toán KNN**
- 4 Frequent Pattern (FBM)

Thuật toán KNN


Giới thiệu

- KNN (K-Nearest Neighbors) là một trong những thuật toán học có giám sát đơn giản nhất được sử dụng nhiều trong khai phá dữ liệu và học máy.
- Ý tưởng: thuật toán này không học một điều gì từ tập dữ liệu huấn luyện (nên KNN được xếp vào loại lazy learning), mọi tính toán được thực hiện khi nó cần dự đoán nhãn của dữ liệu mới.
- Lớp (nhãn) của một đối tượng dữ liệu mới có thể dự đoán từ các lớp (nhãn) của k hàng xóm gần nó nhất.


Thuật toán KNN

Ví dụ minh họa

A. KNN With New Observation, $K=1$



B. KNN With New Observation, $K=5$



Thuật toán KNN

Hàm tính khoảng cách

Hàm tính khoảng cách:

- Đóng vai trò rất quan trọng trong phương pháp học dựa trên các láng giềng gần nhất
- Thường được xác định trước, và không thay đổi trong suốt quá trình học và phân loại/dự đoán

Lựa chọn hàm khoảng cách:

- Các hàm khoảng cách hình học: Dành cho các bài toán có các thuộc tính đầu vào là kiểu số thực
- Hàm khoảng cách Hamming: Dành cho các bài toán có các thuộc tính đầu vào là kiểu nhị phân
- Hàm tính độ tương tự Cosine: Dành cho các bài toán phân lớp văn bản

Khoảng cách hình học có thể được tính theo các chuẩn Euclidean, Manhattan hoặc Minkowski như sau:

$$d_{\text{Manhattan}}(x, y) = \sum_{i=1}^n |x_i - y_i|$$

$$d_{\text{Euclid}}(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

$$d_{\text{Minkowski}}(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}}$$

trong đó, x_i và y_i lần lượt là tọa độ của điểm cần phân loại và điểm lân cận, k là số điểm lân cận được chọn.

Thuật toán KNN

Cách chọn số k

- Chọn k là một công việc quan trọng, các giá trị khác nhau của k có thể dẫn tới hiện tượng overfit hoặc underfit
- Lựa chọn số k là phụ thuộc vào dữ liệu
 - Dùng thư viện Scikit-learn: GridSearchCV hoặc RandomizeSearchCV
 - Sử dụng cross - validation để tìm giá trị k phù hợp
 - Thường chọn $k = \sqrt{n}$
 - Trong bài toán phân lớp nhị phân nên chọn k là số lẻ

Thuật toán KNN

Các bước thực hiện thuật toán KNN

- Bước 1: Xác định tham số k , tức là số láng giềng gần nhất
- Bước 2: Tính toán khoảng cách giữa đối tượng cần phân lớp và tất cả các đối tượng trong dữ liệu huấn luyện
- Bước 3: Sắp xếp các khoảng cách theo thứ tự tăng dần và chọn k láng giềng gần nhất với đối tượng cần phân lớp
- Lấy tất cả các lớp của k láng giềng gần nhất
- Bước 4: Lấy tất cả các lớp của k láng giềng gần nhất
- Bước 5: Dựa vào phần lớn lớp của k láng giềng để xác định lớp cho đối tượng cần phân lớp

Thuật toán KNN

Ưu và nhược điểm của thuật toán KNN

Ưu điểm

- Đơn giản và dễ giải thích
- Không dựa trên bất kỳ giả định nào, vì thế nó có thể được sử dụng trong các bài toán phi tuyến tính.
- Hoạt động tốt trong trường hợp phân loại với nhiều lớp
- Sử dụng được trong cả phân loại và hồi quy

Nhược điểm

- Trở nên rất chậm khi số lượng điểm dữ liệu tăng lên vì mô hình cần lưu trữ tất cả các điểm dữ liệu
- Tốn bộ nhớ
- Nhạy cảm với các dữ liệu bất thường (nhiều)
- Phải lựa chọn hàm tính khoảng cách thích hợp với bài toán

Thuật toán KNN

Áp dụng thuật toán KNN vào nhận dạng khuôn mặt

- Đọc dữ liệu từ file, gán nhãn cho ảnh bằng tên tệp tương ứng với tên từng người
- Xử lý dữ liệu: Làm phẳng dữ liệu ảnh và chuyển dữ liệu thành Numpy array, dtype = float
- Giảm chiều dữ liệu từ kích thước 64x64 thành 10x10. Chia dữ liệu thành tập huấn luyện và tập kiểm tra với tỉ lệ 8 : 2
- Áp dụng thuật toán KNN với $k = 20$ để nhận dạng khuôn mặt sử dụng numpy và gói sklearn.neighbors


Kết quả:

Accuracy	97.35
F1 score	96.75

Thuật toán KNN

Sử dụng cross-validation để chọn tham số k phù hợp

Số k phù hợp là: 5



- 1 Giới thiệu
- 2 Thuật toán di truyền
- 3 Thuật toán KNN
- 4 Frequent Pattern (FBM)

Frequent Pattern (FBM)

1. Giới thiệu

Frequent Pattern Mining (FPM) là khái niệm được dùng trong việc phân tích các hành vi lặp đi lặp lại giữa các yếu tố có liên hệ với nhau. FPM được sử dụng đặc biệt rộng rãi trong các ngành như ecommerce, banking, retail... giúp người bán có thể phân tích hành vi mua sắm của khách hàng. Một số phương pháp được ứng dụng nhiều trong phân tích FPM như:

- Phương pháp Apriori
- Phương pháp Eclat (định dạng dữ liệu dọc - vertical data format)

Frequent Pattern (FBM)

2. Các khái niệm cơ bản

① Market basket analysis (MBA):

- Market basket analysis là phương pháp phân tích giỏ hàng.
- Mục tiêu của phân tích giỏ hàng là xác định tần suất xuất hiện của các mặt hàng cùng mua và tìm ra các quy tắc kết hợp (association rules).
- Mỗi quan hệ giữa các mặt hàng được tìm hiểu để tiên đoán hành vi mua sắm tiếp theo của khách hàng.
- Ví dụ, nếu khách hàng thường mua bia lon và đồ nhậu cùng nhau, ta có thể xác định một quy tắc kết hợp là "Nếu khách hàng mua bia lon, thì họ cũng mua đồ nhậu".
- Phân tích giỏ hàng giúp hiểu hành vi mua sắm của khách hàng và tăng khả năng tiên đoán hành vi mua sắm tiếp theo.

Frequent Pattern (FBM)

2. Các khái niệm cơ bản

- 1 Support và Confidence là hai độ đo quan trọng trong phân tích giỏ hàng.

Giả dụ việc khách hàng mua bia lon và đồ nhậu tại cửa hàng (dựa vào dữ liệu về giao dịch của khách hàng) có xác suất là 2 phần trăm trên tổng số giao dịch và cơ hội để khách hàng mua thêm đồ nhậu khi đã mua bia là 80 phần trăm. Vậy thì hành vi mua sắm bia lon và đồ nhậu được miêu tả như sau: Bia lon \Rightarrow đồ nhậu[support = 0.02, confidence=0.8]. Cụ thể hơn:

- Support: tần suất để hành mua sắm xuất hiện trong toàn bộ các giao dịch mua sắm của khách hàng
- Confidence: cơ hội xảy ra việc mua sắm đồ vật tiếp theo trong chuỗi đồ mua sắm của hành vi
- Mức Support tối thiểu (minimum support threshold): tần suất thấp nhất của hành vi để thỏa mãn được sự quan tâm của người phân tích
- Mức Confidence tối thiểu (minimum confidence threshold): mức thấp nhất của cơ hội mua sắm để thỏa mãn được sự quan tâm của người phân tích

Frequent Pattern (FBM)

2. Các khái niệm cơ bản

① Các khái niệm khác:

Gọi $I = I_1, I_2, \dots, I_m$ là tập các đồ vật, D là dữ liệu giao dịch trong đó từng giao dịch T là giao dịch có các đồ vật thuộc tập I ($T \subset I$). A là tập các đồ vật và $A \subset T$, ta có:

Frequent Pattern (FBM)

2. Các khái niệm cơ bản

$A \Rightarrow B$ khi $A \subseteq I$ & $B \subseteq I$, $A \subsetneq \emptyset$, $B \subsetneq \emptyset$, $A \cap B = \emptyset$ Như vậy, để quy luật $A \Rightarrow B$ sẽ có 2 thành phần: $\text{support}(A \Rightarrow B) = P(A \cup B)$ $\text{confidence}(A \Rightarrow B) = P(A | B)$ Trong đó, $P(A \cup B)$ là tần suất xuất hiện hành vi mua sắm của cả A và B trong dữ liệu về giao dịch D ; $P(A | B)$ là tần suất xuất hiện của hành vi mua sắm B với điều kiện đã có việc mua sắm A.

Frequent Pattern (FBM)

2. Các khái niệm cơ bản

- (*): số lượng giao dịch của cả A và B/Số lượng giao dịch A
Về nguyên tắc, Association rules phải trải qua 2 bước:
- i. Tìm tất cả các giao dịch (tập các đồ vật) phổ biến: các giao dịch này phải thỏa mãn điều kiện về mức support tối thiểu.
- ii. Tạo ra những Association rules mạnh từ các giao dịch phổ biến: các giao dịch có association rules mạnh phải thỏa mãn cả điều kiện về support tối thiểu và confidence tối thiểu.

Frequent Pattern (FBM)

3. Cơ sở toán học

- Cơ sở toán học của khai thác Mẫu thường gặp bao gồm các khái niệm và kỹ thuật từ các ngành toán học khác nhau, Những khái niệm và kỹ thuật này cung cấp nền tảng lý thuyết để hiểu và phân tích các mẫu thường gặp trong dữ liệu.
 - Lý thuyết tập hợp: Biểu diễn giao dịch, tập mục và mẫu.
 - Tổ hợp: Tạo ra các mẫu phổ biến bằng cách kết hợp các mục hoặc tập mục.
 - Lý thuyết xác suất: Xác định xác suất xuất hiện và đồng thời xuất hiện của các mục hoặc tập mục.
 - Thống kê: Đo lường tầm quan trọng và độ tin cậy của các mẫu.

Frequent Pattern (FBM)

4. Phương pháp nghiên cứu

① Trích xuất tính năng LBP:

- LBP là phương pháp đơn giản và hiệu quả để mô tả đặc trưng cục bộ của hình ảnh.
- Nó tính toán các mẫu nhị phân dựa trên các giá trị pixel trong vùng lân cận xung quanh mỗi điểm ảnh.
- Sử dụng hàm `local_binary_pattern` để tính toán LBP với các đối số như hình ảnh đầu vào, số điểm mẫu, bán kính vùng lân cận và phương pháp tính toán LBP.

② Mã hóa tính năng:

- Xây dựng histogram của các mẫu LBP để mã hóa tính năng.
- Sử dụng hàm `histogram` để xây dựng histogram từ mảng giá trị LBP và khoảng giá trị chia histogram.
- Chuẩn hóa histogram bằng cách chia tất cả các giá trị cho tổng của chúng cộng với một giá trị rất nhỏ để tránh chia cho 0.
- Kết quả là một vectơ tính năng đại diện cho mỗi hình ảnh, biểu diễn tần suất của các mẫu LBP trong hình ảnh.

Frequent Pattern (FBM)

5. Triển khai và chi tiết

Được triển khai với Trích xuất tính năng: Các mẫu nhị phân cục bộ (LBP) và Mã hóa tính năng. Phân loại với RandomForestClassifier.

- Như vậy, quy trình dưới đây thực hiện việc trích xuất đặc trưng LBP từ các hình ảnh, tìm kiếm các mẫu phổ biến và sử dụng mô hình RandomForestClassifier để phân loại hình ảnh.

Frequentpattern (FBM)

5. Triển khai và chi tiết

- ➊ Bước 1: Tiền xử lý dữ liệu ảnh bằng cách gán nhãn cho các ảnh và chỉ sử dụng các ảnh định dạng .pgm.
- ➋ Bước 2: Triển khai lớp "LocalBinaryPatterns" và phương thức "describe" để tính toán biểu diễn Local Binary Pattern (LBP) của các hình ảnh.
- ➌ Bước 3: Tạo một đối tượng và tính toán biểu diễn LBP của các hình ảnh, lưu trữ kết quả trong một danh sách đặc trưng.
- ➍ Bước 4: Chia dữ liệu thành tập huấn luyện và tập kiểm tra.
- ➎ Bước 5: Áp dụng thuật toán FP-Growth để tìm các mẫu phổ biến trong tập huấn luyện.
- ➏ Bước 6: Sử dụng mô hình RandomForestClassifier để phân loại các hình ảnh.
- ➐ Bước 7: Đánh giá độ chính xác và F1 Score của mô hình.

Frequent Pattern (FBM)

6. Ưu điểm và nhược điểm

① Ưu điểm:

- Phát hiện mẫu phổ biến
- Khám phá kiến thức ẩn
- Hỗ trợ ra quyết định
- Tính mở rộng

② Nhược điểm

- Độ phức tạp tính toán
- Độ tin cậy của kết quả
- Giới hạn về không gian biểu diễn

Frequent Pattern (FBM)

7. Kết quả và Nhận xét

① Kết quả

- Độ chính xác và F1 Score của mô hình trên tập kiểm tra
- Kết quả đánh giá hiệu suất của mô hình cho thấy độ chính xác của mô hình là X % và F1 Score là Y%

② Nhận Xét

- Phương pháp trích xuất tính năng LBP đã cho kết quả tốt trong việc biểu diễn đặc trưng cục bộ của hình ảnh
- Mã hóa tính năng bằng cách xây dựng histogram của các mẫu LBP đã mang lại kết quả tốt trong việc biểu diễn đặc trưng của hình ảnh
- Mô hình RandomForestClassifier đã cho hiệu suất tốt trong việc phân loại
- hiệu suất của mô hình có thể thay đổi tùy thuộc vào bộ dữ liệu và phương pháp trích xuất tính năng.
- phương pháp Frequent Pattern đã mang lại kết quả khả quan trong việc trích xuất và mã hóa tính năng. các đối tượng trong bộ dữ liệu

**CẢM ƠN THẦY VÀ CÁC BẠN
ĐÃ LẮNG NGHE!**